PROJET DE MACHINE LEARNING :
PREDICTION DE LA SOUSCRIPTION A UN DEPOT BANCAIRE

Approche de classification supervisée sur le Dataset : Bank Marketing
UCI Machine Learning Repository

KHADY DIAGNE
ETUDIANTE EN MASTER 2 SCIENCES DES DONNEES - IDMC (UNIVERSITE DE LORRAINE)

Table des matières

Étape 1 : Présentation du dataset et définition du problème 2

1. Présentation du jeu de données 2
2. Description des variables 2
3. Définition du problème 3
4. Traitement particulier de la variable duration 3

Étape 2 : Analyse exploratoire 4

1. Répartition de la cible 4
2. Analyse descriptive 4
3. Corrélations et multicolinéarité 5

Étape 3 : Méthodologie 6

1. Séparation des données 6
2. Pipeline de prétraitement 6
3. Modélisation par Régression Logistique 6
4. Modèle comparatif : Random Forest 7

Étape 4 : Présentation des résultats 7

1. Régression logistique 7
2. Random Forest 8
3. Comparaison synthétique 9
4. Interprétation des modèles 10

Conclusion 10

Étape 1 : Présentation du dataset et définition du problème

1. Présentation du jeu de données

Le jeu de données utilisé est **Bank Marketing (bank-additional-full.csv),** issu du UCI Machine Learning Repository. Il provient de campagnes de marketing direct menées par une institution bancaire portugaise entre 2008 et 2010.

Référence : Moro, S., Cortez, P., & Rita, P. (2014). *A Data-Driven Approach to Predict the Success of Bank Telemarketing*. Decision Support Systems.
Le dataset contient initialement 41 188 observations et 21 variables (20 variables explicatives et 1 variable cible). Après suppression de 12 doublons, l'échantillon final comprend 41 176 observations.
Les variables se répartissent comme suit :

- 10 variables numériques
- 10 variables catégorielles
- 1 variable cible

Aucune valeur manquante n'est observée dans les données. Certaines variables catégorielles contiennent toutefois la modalité **"unknown"**, qui est conservée comme catégorie distincte.

2. Description des variables

Les variables du dataset peuvent être regroupées en plusieurs catégories :

1) Variables socio-démographiques et financières

- age : âge du client (variable numérique)
- job : profession du client (catégorielle)
- marital : statut matrimonial (catégorielle)
- education : niveau d'éducation (catégorielle)
- default : existence d'un défaut de crédit (catégorielle)
- housing : présence d'un prêt immobilier (catégorielle)
- loan : présence d'un prêt personnel (catégorielle)

2) Variables liées à la campagne en cours

- contact : type de contact utilisé lors de la campagne
- month : mois du dernier contact
- day_of_week : jour de la semaine du dernier contact
- campaign : nombre de contacts effectués durant la campagne

3) Variables liées aux campagnes précédentes

- pdays : nombre de jours écoulés depuis le dernier contact lors d'une campagne précédente

- previous : nombre de contacts réalisés avant la campagne actuelle
- poutcome : résultat de la campagne précédente

4) Variables de contexte socio-économique

- emp.var.rate : taux de variation de l'emploi
- cons.price.idx : indice des prix à la consommation
- cons.conf.idx : indice de confiance des consommateurs
- euribor3m : taux Euribor à trois mois
- nr.employed : nombre de personnes employées

5) Variable cible

- y : souscription à un dépôt à terme

3. Définition du problème

L'objectif du projet est de prédire la probabilité qu'un client **souscrive à un dépôt bancaire** à l'issue d'une campagne de marketing direct.
La variable cible Yindique si le client a souscrit à un dépôt à terme :

- $Y = 1$: souscription
- $Y = 0$: non souscription

La distribution de la cible est la suivante :

- 36 548 observations (88.73 %) : classe "no"
- 4 640 observations (11.27 %) : classe "yes"

Il s'agit donc d'un **problème de classification supervisée binaire avec déséquilibre de classes**.

D'un point de vue probabiliste, on cherche à estimer :

$$P(Y = 1 \mid X = x)$$

Où Ysuit une loi de Bernoulli conditionnellement aux variables explicatives X.
Et X représente le vecteur des variables explicatives décrivant les caractéristiques du client, l'historique de campagne et le contexte macroéconomique.

4. Traitement particulier de la variable duration

La variable duration correspond à la durée du dernier appel téléphonique. Cette information n'est connue qu'après la fin du contact client. Son utilisation dans un modèle prédictif introduirait une fuite d'information (data leakage).
Elle est donc exclue de la modélisation afin de conserver un cadre prédictif réaliste.

Étape 2 : Analyse exploratoire

L'analyse exploratoire constitue une étape essentielle afin de comprendre la structure du jeu de données et d'identifier les variables susceptibles d'influencer la modélisation. Après suppression des doublons, la base de données contient 41 176 observations et 21 variables.

1. Répartition de la cible

La distribution de la cible met en évidence un fort déséquilibre de classes :

- Classe positive : 11.27 %
- Classe négative : 88.73 %

Dans ce contexte, l'utilisation de l'**accuracy seule** peut être trompeuse. Des métriques complémentaires telles que **precision, recall, F1-score et ROC-AUC** sont donc utilisées.

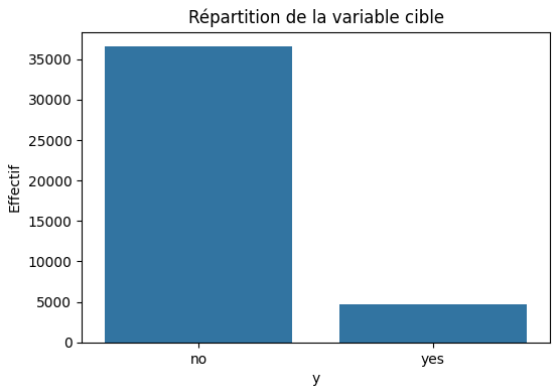

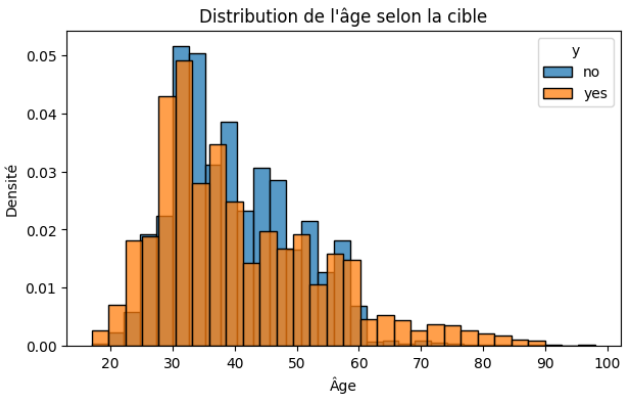

2. Analyse descriptive

Les statistiques descriptives des variables numériques indiquent :

- Âge moyen : 40 ans
- Médiane âge : 38 ans
- Nombre moyen de contacts (campaign) : 2.57

Les variables macroéconomiques présentent des variations limitées mais structurées. Certaines variables présentent des distributions asymétriques avec des valeurs extrêmes, notamment campaign et duration.

La variable pdays présente une particularité importante : une grande proportion d'observations prend la valeur 999, indiquant l'absence de contact lors d'une campagne précédente.

	count	mean	std	min	25%	50%	75%	max
age	41176.0	40.023800	10.420680	17.000	32.000	38.000	47.000	98.000
duration	41176.0	258.315815	259.305321	0.000	102.000	180.000	319.000	4918.000
campaign	41176.0	2.567879	2.770318	1.000	1.000	2.000	3.000	56.000
pdays	41176.0	962.464810	186.937102	0.000	999.000	999.000	999.000	999.000
previous	41176.0	0.173013	0.494964	0.000	0.000	0.000	0.000	7.000
emp_var_rate	41176.0	0.081922	1.570883	-3.400	-1.800	1.100	1.400	1.400
cons_price_idx	41176.0	93.575720	0.578839	92.201	93.075	93.749	93.994	94.767
cons_conf_idx	41176.0	-40.502863	4.627860	-50.800	-42.700	-41.800	-36.400	-26.900
euribor3m	41176.0	3.621293	1.734437	0.634	1.344	4.857	4.961	5.045
nr_employed	41176.0	5167.034870	72.251364	4963.600	5099.100	5191.000	5228.100	5228.100

3. Corrélations et multicolinéarité

La matrice de corrélation de Pearson met en évidence des corrélations élevées entre certaines variables macroéconomiques, notamment : euribor3m, emp_var_rate et nr_employed.
Ces corrélations suggèrent une multicolinéarité potentielle, qui peut affecter l'interprétation des coefficients dans les modèles linéaires. L'utilisation d'une régularisation L2 permet toutefois d'atténuer ce phénomène.

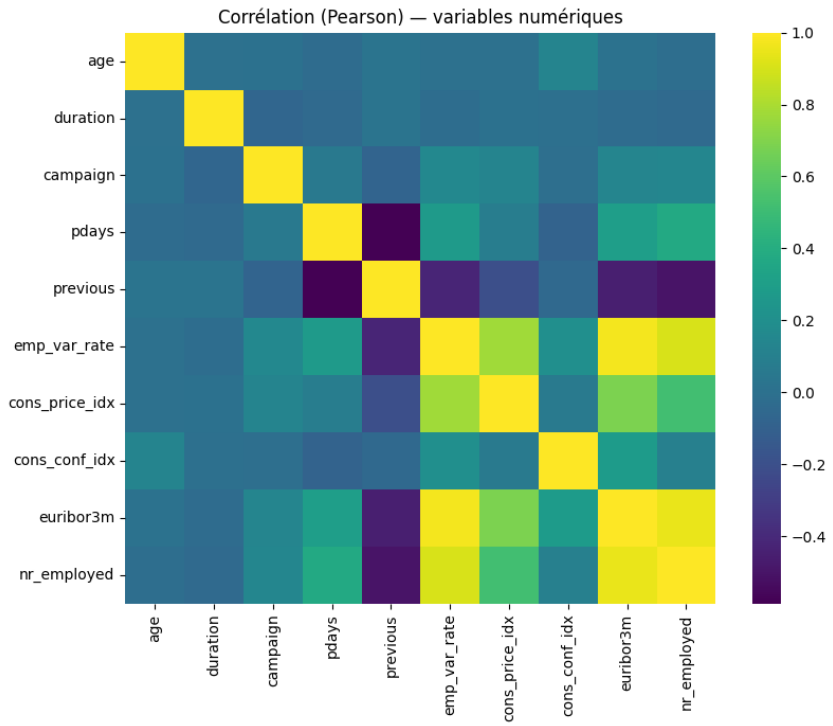

Étape 3 : Méthodologie

1. Séparation des données

Les données sont séparées en 80 % de train & 20 % de test. Un **split stratifié** est utilisé afin de préserver la proportion de la classe positive dans les deux ensembles.

2. Pipeline de prétraitement

Un pipeline basé sur **ColumnTransformer** est mis en place :

- Variables numériques : SimpleImputer & StandardScaler
- Variables Catégorielles : SimpleImputer & OneHotEncoder

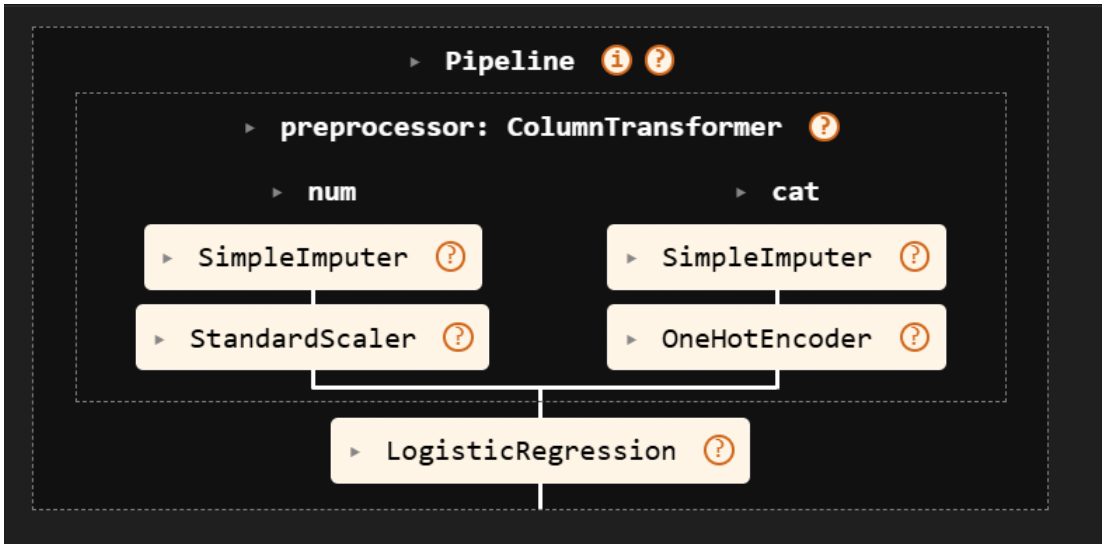

Cette approche garantit :

- L'absence de fuite d'information,
- La cohérence entre entraînement et évaluation,
- Et la reproductibilité du processus de modélisation.

3. Modélisation par Régression Logistique

La régression logistique est un modèle de classification supervisée permettant de modéliser la probabilité d'appartenance à une classe binaire.

La probabilité qu'une observation appartienne à la classe positive est donnée par :

$$P(Y = 1 \mid X = x) = \frac{1}{1 + e^{-(\beta_0 + \beta_1 x_1 + \cdots + \beta_p x_p)}}$$

Où :

- x représente le vecteur des variables explicatives

- β_0 est l'interception du modèle
- β est le vecteur des coefficients associés aux variables explicatives

Les paramètres du modèle sont estimés en minimisant la **fonction de perte logistique (log-loss)** :

$$L(\beta) = -\sum_{i=1}^{n}[y_i \log(p_i) + (1 - y_i)\log(1 - p_i)]$$

où :

- y_i représente la valeur observée de la variable cible
- $p_i = P(Y = 1 \mid X_i)$ est la probabilité prédite par le modèle

Une version **pondérée du modèle** est également testée afin de mieux prendre en compte le déséquilibre de classes.

4. Modèle comparatif : Random Forest

La **Random Forest** est un modèle d'ensemble basé sur un grand nombre d'arbres de décision entraînés sur des sous-échantillons des données.

Ce modèle permet de :

- Capturer des relations non linéaires,
- Modéliser des interactions entre variables,
- De réduire la variance grâce à l'agrégation des arbres.

Une optimisation légère des hyperparamètres est réalisée à l'aide de GridSearchCV.

Étape 4 : Présentation des résultats

Les performances des modèles sont évaluées à l'aide de plusieurs métriques : accuracy, precision, recall, F1-score et ROC-AUC.

1. Régression logistique

Modèle standard

- Accuracy : 0.898
- Precision : 0.651
- Recall : 0.209
- F1 : 0.316
- ROC-AUC : 0.8004

Le modèle standard présente une bonne précision mais un **faible rappel de la classe positive**.

Modèle pondéré

- Accuracy : 0.830
- Precision : 0.359
- Recall : 0.645
- F1 : 0.462
- ROC-AUC : 0.800

La pondération améliore significativement la détection de la classe minoritaire.

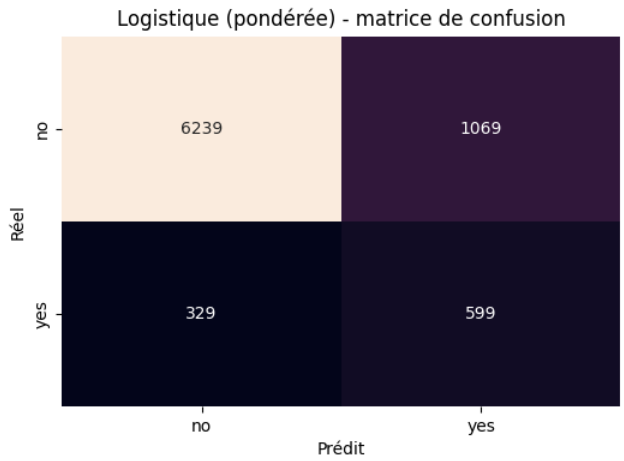

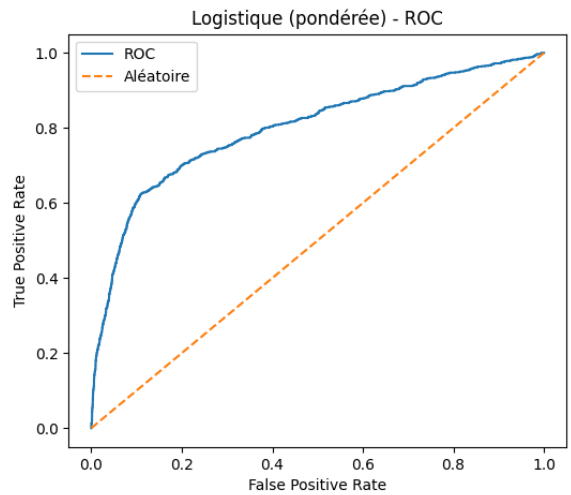

2. Random Forest

Modèle de base :

- Accuracy : 0.893
- Precision : 0.553
- Recall : 0.287
- F1 : 0.378
- ROC-AUC : 0.777

Modèle optimisé (tuned)

Avec les meilleurs paramètres :

- max_depth = 10
- max_features = 0.5
- min_samples_leaf = 5
- n_estimators = 200

Et les performances sont :

- Accuracy : 0.901
- Precision : 0.645
- Recall : 0.261

- F1 : 0.372
- ROC-AUC : 0.813

La Random Forest obtient le **meilleur ROC-AUC**, indiquant une meilleure capacité globale de discrimination.

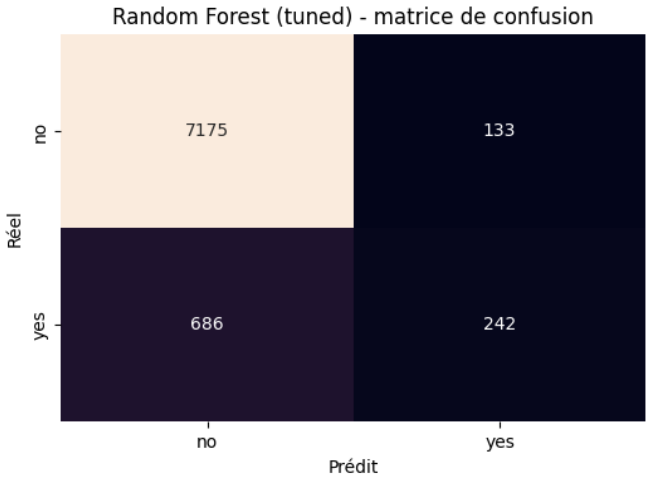

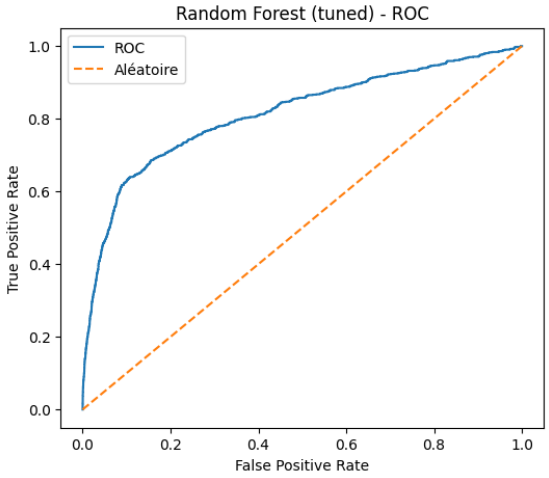

3. Comparaison synthétique

Modèle	Accuracy	Precision	Recall	F1 Score	ROC-AUC
Logistique (base)	0.898	**0.651**	0.209	0.316	0.800
Logistique (pondérée)	0.830	0.359	**0.646**	**0.462**	0.800
RF (base)	0.894	0.553	0.287	0.378	0.778
RF (tuned)	**0.901**	0.645	0.261	0.372	**0.814**

La comparaison des modèles montre que les approches testées présentent des comportements différents face au déséquilibre de classes du dataset.

La régression logistique standard obtient une accuracy élevée (0.898) mais un recall faible (0.209) pour la classe positive. Cela signifie que le modèle prédit majoritairement la classe négative, ce qui est fréquent lorsque la classe majoritaire domine fortement les données.

L'introduction d'une pondération des classes améliore nettement la capacité du modèle à détecter les souscriptions (recall = 0.646), au prix d'une diminution de la précision. Ce comportement est typique des modèles appliqués à des jeux de données déséquilibrés.

La Random Forest optimisée obtient le meilleur ROC-AUC (0.814), indiquant une meilleure capacité globale de discrimination entre les classes. Cependant, son recall reste plus faible que celui de la régression logistique pondérée.

Ces résultats illustrent le **compromis classique entre interprétabilité et performance** : la régression logistique est plus facile à interpréter, tandis que la Random Forest capture plus efficacement les relations complexes entre variables.

Le choix dépend de l'objectif métier :

- Pour maximiser la détection -> logistique pondérée
- Pour maximiser la discrimination globale -> RF tuned

4. Interprétation des modèles

L'analyse des coefficients de la régression logistique montre que plusieurs variables influencent significativement la probabilité de souscription. Par exemple, la variable month_mar présente l'effet positif le plus élevé. L'odds ratio associé est d'environ 3.47, ce qui indique qu'un contact effectué au mois de mars multiplie par plus de trois les chances de souscription.

Certaines variables socio-démographiques, comme job_retired, sont également associées à une probabilité plus élevée de réponse positive. De même, la variable poutcome_success indique qu'un succès lors d'une campagne précédente augmente la probabilité de souscription.

L'analyse des importances dans la Random Forest met en évidence le rôle majeur des variables macroéconomiques, notamment nr_employed et euribor3m.

Ces résultats suggèrent que la probabilité de souscription dépend à la fois :

- Des caractéristiques individuelles des clients,
- De l'historique des campagnes marketing,
- Et du contexte macroéconomique.

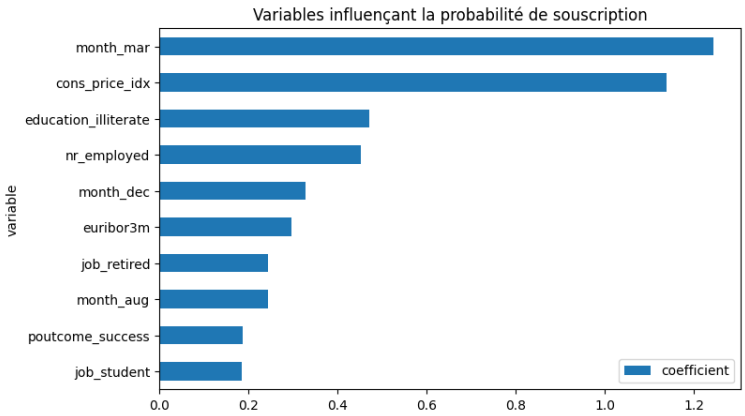

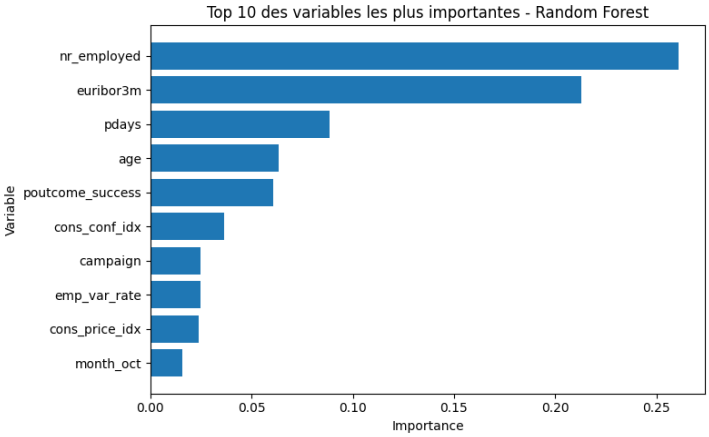

Conclusion

Ce projet a permis d'étudier différentes approches de classification afin de prédire la souscription à un dépôt bancaire à partir de données clients et de variables macroéconomiques issues du dataset Bank Marketing.

Les résultats montrent que la **Random Forest optimisée** offre la meilleure capacité globale de discrimination, tandis que la **régression logistique pondérée** améliore significativement la détection de la classe minoritaire. Ces résultats illustrent l'importance de comparer plusieurs modèles et d'adapter l'évaluation aux caractéristiques du jeu de données.

Dans un contexte de classification déséquilibrée, l'accuracy seule ne constitue pas une métrique suffisante. L'analyse conjointe de métriques telles que le recall, le F1-score et la ROC-AUC permet d'obtenir une évaluation plus pertinente de la performance des modèles.

L'interprétation des modèles met également en évidence l'influence de certaines variables macroéconomiques, notamment **euribor3m** et **nr_employed**, suggérant que la probabilité de souscription dépend à la fois des caractéristiques individuelles des clients et du contexte économique dans lequel les campagnes marketing sont menées.

Enfin, certaines limites doivent être soulignées. La présence de corrélations élevées entre certaines variables peut affecter l'interprétation des modèles linéaires. De plus, le déséquilibre de classes limite la capacité des modèles à détecter parfaitement la classe positive, ce qui constitue une difficulté classique dans les problèmes de classification appliqués aux données réelles.